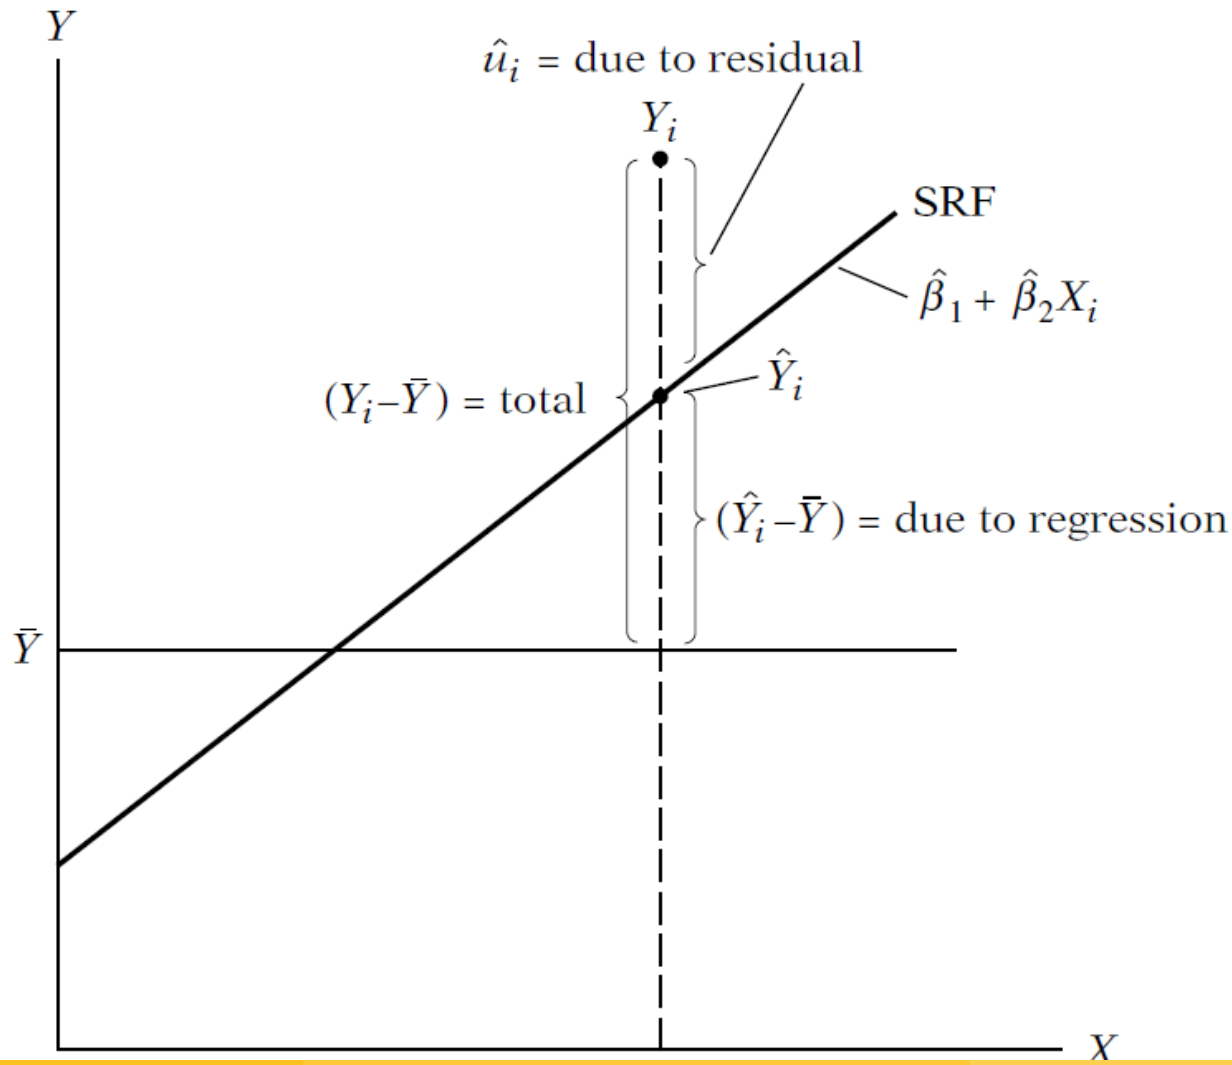
# Регрессионный анализ: продолжение

Меры качества линейной регрессионной модели
Сравнение альтернативных спецификаций

2 ноября 2026

# Разложение дисперсии в линейной регрессии: визуализация

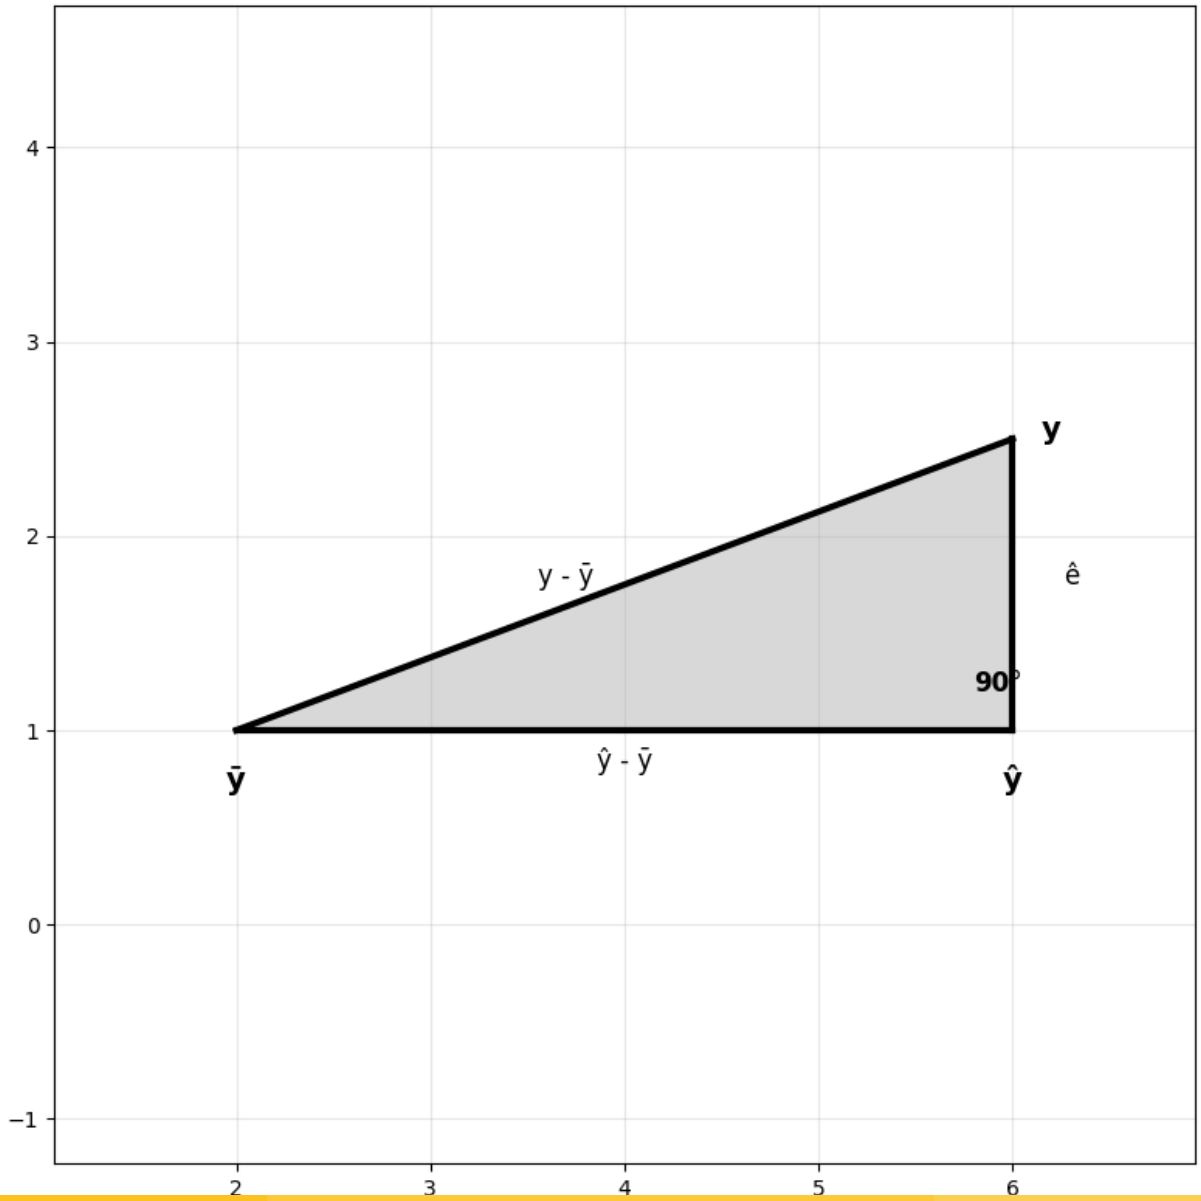


# ANOVA-таблица

| | df | SS | MSS | $F$ |
|---|---|---|---|---|
| x | $k$ | ESS | $\frac{\text{ESS}}{k}$ | $\frac{\text{ESS}/k}{\text{RSS}/(n-k-1)}$ |
| Residual | $n-k-1$ | RSS | $\frac{\text{RSS}}{n-k-1}$ | |
| Total | $n-1$ | TSS | | |

Примечание:
$k$ – количество предикторов
$n$ – количество наблюдений

# Геометрическая интерпретация $R^2$



# Геометрическая интерпретация $R^2$

Пусть $\alpha$ – это угол между векторами $\vec{y} - \bar{y} \times \vec{1}$ и $\vec{\hat{y}} - \bar{y} \times \vec{1}$

$$R^2 = \frac{ESS}{TSS} = \frac{\|\vec{\hat{y}} - \bar{y} \times \vec{1}\|^2}{\|\vec{y} - \bar{y} \times \vec{1}\|^2} = cos^2\alpha = cor^2(y_i, \hat{y}_i)$$

$$cos\alpha = \frac{(\vec{y} - \bar{y} \times \vec{1}) \cdot (\vec{\hat{y}} - \bar{y} \times \vec{1})}{\|\vec{y} - \bar{y} \times \vec{1}\| \|\vec{\hat{y}} - \bar{y} \times \vec{1}\|} = \frac{\sum_{i=1}^n (y_i - \bar{y})(\hat{y}_i - \bar{y})}{\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2} \sqrt{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}}$$

$$= cor(y_i, \hat{y}_i)$$

# Проблема переобучения

При переобучении наблюдается существенная разница в объяснительной силе модели на обучающей и тестовой выборке. Модель по сути перестает быть моделью, а просто описывает обучающие данные, подстраиваясь под особенности обучающей выборки. Таким образом, при переобучении

- обобщающая способность модели (возможность перенести результаты на другую выборку) низкая
- результаты оценивания модели неустойчивы

В частности, сильная мультиколлинеарность может способствовать переобучению

# $R^2$ скорректированный

Вне зависимости от того, добавили ли мы в модель значимые или незначимые для объяснения дисперсии зависимой переменной предикторы, коэффициент детерминации $R^2$ не убывает. Поэтому для того, чтобы учесть случай, когда некоторые параметры могут оказаться бесполезными в нашей спецификации модели, мы будем использовать альтернативу - $R^2_{adj}$ ($R^2$ скорректированный не превышает $R^2$: $R^2_{adj} \leq R^2$)
В $R^2$ скорректированном мы вводим корректировку на количество степеней свободы (см. таблицу разложения дисперсии ANOVA):

$$R^2_{\text{adj}} = 1 - \frac{\frac{RSS}{n-k-1}}{\frac{TSS}{n-1}} = 1 - \frac{RSS(n-1)}{TSS(n-k-1)} = 1 - (1-R^2)\frac{n-1}{n-k-1}$$

# Вложенные VS Невложенные модели

## Вложенные модели (Nested Models)

Мы можем получить спецификацию одной из другой посредством только добавления или только исключения параметров. Пример:

$$M_1 : \hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i}$$
$$M_2 : \hat{y}_i = \hat{\alpha}_0 + \hat{\alpha}_1 x_{1i} + \hat{\alpha}_2 x_{2i}$$

## Невложенные модели (Non-nested Models)

Получить одну из другой только исключением или только добавлением параметров невозможно. Пример:

$$M_1 : \hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i}$$
$$M_3 : \hat{y}_i = \hat{\gamma}_0 + \hat{\gamma}_2 x_{3i}$$

# Информационные критерии

$$IC = -2lnL + c$$

Чем лучше модель описывает данные, тем больше функция правдоподобия: $-2ln(L)$ — это мера «плохости» подгонки. Чем меньше значение $-2ln(L)$, тем лучше модель
$c$ – штраф на добавление параметров
AIC – Akaike Information Criterion
BIC – Bayesian Information Criterion

$$AIC = -2lnL + 2p$$

$$BIC = -2lnL + p\ln(N)$$

p – количество параметров в регрессионной модели;
N – размер выборки;
lnL – натуральный логарифм функции правдоподобия модели

# Какой вывод делаем по IC?

Мы рассчитываем информационные критерии (AIC / BIC) для альтернативных моделей, оцененных на одном наборе данных, и сравниваем значения AIC / BIC. Само по себе значение IC ничего не говорит, важно только в сравнительной перспективе

Чем меньше значение рассчитанного информационного критерия (AIC/BIC), тем модель лучше

Эмпирическое правило: если разница между информационными критериями оцененных моделей превышает 10, то одна модель считается существенно лучше, чем другая. Если разница меньше, то значимой разницы между моделями нет

# F-тест для вложенных моделей

$$M_short : \hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \ldots + \hat{\beta}_k x_{ki}$$
$$M_full : \hat{y}_i = \hat{\gamma}_0 + \hat{\gamma}_2 x_{1i} + \ldots + \hat{\gamma}_k x_{ki} + \hat{\gamma}_{k+1} x_{(k+1)i} + \ldots + \hat{\gamma}_{k+j} x_{(k+j)i}$$

$$H_0 : \gamma_{k+1} = \ldots = \gamma_{k+j} = 0$$

При верной $H_0$ справедливо, что

$$F = \frac{(RSS_{short} - RSS_{long})/\Delta df}{RSS_{long}/df_{long}} \sim F(\Delta df, df_{long})$$

Если p-value достаточно велико, то делаем выбор в пользу модели более экономной (с меньшим количеством параметров)


ВОПРОСЫ?